

**Maria Cláudia Geloneze Cangussú - RA: 208730-6**  
**Mariana da Silva -Q RA:**  
**Murilo Tozoni - RA:**

**Inteligência Artificial - 3o Termo**

# **Relatório Técnico: Predição da Qualidade de Vinhos Utilizando Técnicas de Machine Learning**

## **1. INTRODUÇÃO**

A avaliação da qualidade dos vinhos desempenha um papel importante na definição de valor de mercado e na aceitação do produto pelo consumidor. Tradicionalmente, esse processo depende da análise humana sensorial de especialistas (enólogos) combinada a testes químicos.

O papel da Ciência de Dados nesse cenário é atuar como uma ferramenta auxiliar e objetiva, identificando padrões ocultos nas interações químicas que determinam a qualidade do produto. O problema prático que buscamos resolver consiste em determinar se um lote de vinho pode ser classificado como "excelente" utilizando apenas métricas de laboratório, permitindo que produtores otimizem seus critérios de controle de qualidade.

## **2. OBJETIVOS**

Desenvolver e otimizar modelos de Inteligência Artificial para classificar vinhos tintos entre alta e baixa qualidade a partir de suas propriedades físico-químicas, além disso, tem como objetivo:

- Investigar e higienizar o conjunto de dados por meio de Análise Exploratória
- Tratar e transformar a variável alvo para o formato binário.
- Implementar ferramentas de blindagem contra o vazamento de dados
- Treinar, testar e comparar o desempenho dos algoritmos Regressão Logística, KNN e Random Forest utilizando Validação Cruzada Estratificada.
- Analisar a importância e influência das variáveis (coeficientes) no modelo de Regressão Logística vencedor.

### 3. DESCRIÇÃO DO DATASET

O conjunto de dados wine-quality continha originalmente 1.599 registros e 12 colunas. Após a etapa essencial de pré-processamento para limpeza de dados duplicados, o conjunto final passou a contar com 1.359 registros.

A variável alvo quality (notas de 3 a 8) foi transformada em quality\_bin onde notas  $\geq 7$  representam a classe 1 (Vinho Bom) e notas  $< 7$  representam a classe 0 (Vinho Comum/Ruim). Os atributos preditores incluem características químicas como Acidez Fixa, Acidez Volátil, Ácido Cítrico, Açúcar Residual, Cloretos, Dióxido de Enxofre Livre e Total, Densidade, pH, Sulfatos e Álcool.

### 4. METODOLOGIA

O fluxo aplicado garantiu a qualidade do aprendizado e a integridade estatística dos dados através das seguintes etapas:

#### 4.1 Carregamento e Higienização

Os dados foram importados via Pandas a partir do arquivo CSV original, sem a presença de valores nulos. Para evitar viés de observações repetidas, removemos 240 registros duplicados, reduzindo o dataset para 1.359 linhas únicas.

#### 4.2 Análise Exploratória de Dados (EDA)

A investigação inicial das variáveis revelou os seguintes comportamentos:

- **Transformação Binária:** Devido à concentração de notas intermediárias (5 e 6), convertemos o alvo para um problema binário : notas maiores ou igual a 7 viraram Vinho Bom (Classe 1) e notas menores que 7 viraram Vinho Ruim/Comum (Classe 0), o que evidenciou um forte desbalanceamento de classes.
- **Correlações e Outliers:** O teor alcoólico demonstrou alta correlação positiva com a qualidade, enquanto a acidez volátil mostrou impacto negativo. Foram detectados *outliers* significativos em atributos como total sulfur dioxide.

#### 4.3 Pré-processamento e Divisão

Após isolar a variável alvo, aplicamos uma Divisão Estratificada (60% / 20% / 20%), isso garantiu a preservação da proporção exata entre as classes desbalanceadas nos três conjuntos finais:

- **Treino:** 815 amostras (usadas para o aprendizado do modelo).
- **Validação:** 272 amostras (usadas na validação cruzada).
- **Teste:** 272 amostras (isoladas para a avaliação cega final).

## 5. MODELAGEM

Foram implementados três modelos distintos para avaliação:

- *Regressão Logística*: Modelo linear, rápido e de alta explicabilidade estatística através de seus coeficientes.
- *K-Nearest Neighbors (KNN)*: Algoritmo baseado em distância, que avalia a vizinhança dos dados sem assumir distribuições prévias.
- *Random Forest*: Modelo de Ensemble baseado em múltiplas árvores de decisão.

## 6. TREINAMENTO E VALIDAÇÃO CRUZADA (CROSS-VALIDATION)

Os modelos foram submetidos à rotina de validação cruzada para cada na métrica F1-Score Macro, resultando nos seguintes desempenhos médios:

- *Logistic Regression*: F1 Treino (CV): 0.6968 | F1 Teste (CV): 0.6943
- *KNN*: F1 Treino (CV): 0.7676 | F1 Teste (CV): 0.6783
- *Random Forest*: F1 Treino (CV): 1.0000 | F1 Teste (CV): 0.6704

O KNN e o Random Forest, apresentaram *overfitting*. O Random Forest atingiu 100% no treino, memorizando os dados, mas seu desempenho caiu no teste. A Regressão Logística apresentou a maior estabilidade entre treino e validação, sem indícios de memorização.

## 6. AVALIAÇÃO FINAL NO CONJUNTO DE TESTE ISOLADO

Submetendo os modelos consolidados ao conjunto de dados de teste final e inédito, extraímos o seguinte DataFrame consolidado de resultados:

| Algoritmo           | Acurácia | Precisão (Macro) | Recall (Macro) | F1-Score (Macro) | AUC-R OC      |
|---------------------|----------|------------------|----------------|------------------|---------------|
| Logistic Regression | 76,83%   | 66,40%           | 80,90%         | <b>67,64%</b>    | <b>0,8834</b> |
| KNN                 | 86,02%   | 68,93%           | 63,45%         | 65,41%           | 0,7847        |

|                      |        |        |        |        |        |
|----------------------|--------|--------|--------|--------|--------|
| <b>Random Forest</b> | 87,50% | 75,17% | 59,74% | 62,55% | 0,8715 |
|----------------------|--------|--------|--------|--------|--------|

## 7. ANÁLISE DOS RESULTADOS

A escolha do modelo de Regressão Logística como o campeão definitivo baseia-se na análise das seguintes fases:

- *Matrizes de Confusão:* Em problemas desbalanceados onde a classe positiva (Vinho Bom) é rara, a Acurácia engana. O Random Forest teve 87,50% de acurácia porque acertou 230 vinhos ruins, mas falhou criticamente nos vinhos bons: deixou passar 29 Falsos Negativos e encontrou apenas 8 Verdadeiros Positivos. A Regressão Logística encontrou 32 Verdadeiros Positivos (vinhos excelentes detectados com sucesso) e teve apenas 5 Falsos Negativos. Embora tenha gerado mais Falsos Positivos (58), seu Recall para a classe minoritária é superior e mais útil para o contexto.
- *Curva ROC e AUC:* A comparação das curvas de desempenho confirmou o domínio da Regressão Logística, que traçou a parábola mais próxima do topo esquerdo, atingindo uma Área Sob a Curva de 0,88, acima do Random Forest (0,87) e KNN (0,78).

## 8. LIMITAÇÕES DO PROJETO

O estudo possui limitações que garantem uma interpretação realista:

1. Desbalanceamento Inerente: Existem, na natureza do dataset, muito mais vinhos comuns do que excelentes, dificultando o aprendizado.
2. Redução Volumétrica: Após a exclusão de 240 duplicatas, a base tornou-se menor, impactando certas métricas absolutas, mas tornando a avaliação final estatisticamente confiável.
3. Redução da Granularidade: A classificação binária agrupa notas muito diferentes (ex: nota 3 e nota 6) em uma mesma classe genérica (0).

## 9. CONCLUSÃO

As implementações realizadas provaram que técnicas de proteção de dados, como Validação Cruzada e Pipelines, são indispensáveis, sem essas ferramentas, teríamos escolhido o Random Forest enganados por seus números inflados de overfitting, implementando um modelo que falharia no mundo real ao ignorar os melhores vinhos.

A escolha da Regressão Logística como modelo campeão demonstrou ser a decisão estatística mais sensata e equilibrada. Além de lidar de forma superior com o

desbalanceamento das classes para identificar os vinhos de excelência (maior *Recall*), o algoritmo linear conferiu total transparência ao processo, permitindo auditar exatamente quais componentes químicos — como o teor alcoólico e os sulfatos — mais impactam a qualidade final da bebida.

Do ponto de vista prático, o sistema cumpre o seu objetivo principal: ser uma ferramenta de triagem automatizada, rápida e objetiva, reduzindo o peso e os custos das análises sensoriais manuais.